

Tuna-2: Pixel Embeddings Beat Vision Encoders for Multimodal Understanding and Generation

Zhiheng Liu^{*1,2} Weiming Ren^{*1,3} Xiaoke Huang¹ Shoufa Chen¹ Tianhong Li¹
Mengzhao Chen² Yatai Ji² Sen He¹ Jonas Schult¹ Belinda Zeng¹
Tao Xiang¹ Wenhui Chen³ Ping Luo² Luke Zettlemoyer¹ Yuren Cong¹

¹Meta AI ²The University of Hong Kong ³University of Waterloo



CVPR2026 Highlight


王锦

2026.05.20

Task&Background

视觉理解与**生成**是多模态 AI 的两大核心能力。
原生统一多模态模型 (UMM)想在单一框架中同时建模这两种能力。

模块化设计 (Pre-trained Vision Encoder+Projector+LLM)



- 不是“真正统一”：理解与生成使用的视觉空间不一致
- 语义与细节难以平衡
- 连接器需人工设计，比较繁琐。
- 信息瓶颈：依赖预训练视觉编码器

理解

图像问答、OCR、图表理解、细粒度视觉推理等。

生成

文生图、图像编辑、视频生成。

早期：解耦表示


使用 CLIP 等表示编码器用于理解

使用 VQ-VAE 等面向重建的编码器用于生成。


近期：共享视觉编码器，统一视觉表示。

Architecture


TUNA



TUNA-R



TUNA-2



Patch Embedding

14 Grid



14 Grid

224

1x1Conv (C=768)

Vision Token

与LLM词向量维度对齐

共享Transformer Blocks


理解与生成任务共享同一套Transformer层,
通过注意力掩码动态隔离

不同任务激活不同的任务头

- 语言建模头 (Language Modeling Head)
- 流匹配头 (Flow Matching Head)


理解和生成共享表示空间

Vision Transformer (ViT)




Generation: Pixel-Space Flow Matching

Latent-Space




Pixel-Space



Flow Matching

学习一个“速度场”，告诉某个位置的像素在时间 t 应该往哪个方向移动。




$$\frac{dx_t}{dt} = x_1 - x_0 \quad v_\theta(x_t, t)$$

训练时：通过最小化流匹配损失函数（Flow Matching Loss），让预测的向量场去逼近真实的概率密度流动的路径。

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t,x_0,x_1} \left[\|v_\theta(x_t, t) - u_t\|^2 \right]$$

生成时：沿速度场从噪声流向数据。




Training

Masking-Based Feature Learning

- 像素空间维度高、冗余多，模型易学捷径
- 无视觉编码器的设计，模型缺乏视觉先验，学习困难

MAE：遮住图像 patch→重建被遮住 patch



随机掩码patch，mask token 由learnable mask token 替代。

2-Stage End2End Training Strategy

Phase 1: Pre-Train

在包含**5.5亿**图像-文本对的数据集上进行训练。数据在图像字幕（70%）和文本到图像生成（30%）之间进行平衡，并额外添加20%的纯文本数据以保持LLM的语言能力。

Phase 2: SFT

在包含**1500万**个示例的精选语料库上进行微调。包括用于视觉理解的指令遵循数据（FineVision）、图像编辑数据（OmniEdit）以及用于生成的高质量合成图像。

Results

图像理解（9个通用VQA Benchmark+3个以像素为中心的Benchmark）

Models	Size	General Benchmarks									Pixel-centric Benchmarks		
		GQA	RealWorldQA	MMVet	MMMU	MMVP	SEED-Bench2+	AI2D	ChartQA	OCRBench	V*	CountBench	VisuLogic
Understanding-only Models (LMMs)													
LLaVA-1.5 (Liu et al., 2023)	7B	62.0	54.8	32.9	35.7	-	-	55.5	17.8	31.8	-	-	-
Qwen-VL-Chat (Bai et al., 2023)	7B	57.5	49.3	47.3	37.0	-	-	57.7	49.8	48.8	-	-	-
LLaVA-OV (Li et al., 2024a)	7B	-	69.9	51.9	48.8	77.3	62.2	81.4	80.9	62.2	72.7	76.2	24.8
Qwen2.5-VL (Li et al., 2024a)	7B	60.7	69.9	61.7	58.6	78.0	70.5	82.7	83.0	83.7	71.2	74.1	20.0
Composite UMMs													
TokenFlow-XL (Qu et al., 2025)	14B	62.5	56.6	-	43.2	-	-	-	-	-	-	-	-
BLIP3-o (Chen et al., 2025a)	4B	-	60.4	-	46.6	-	-	-	-	-	-	-	-
Tar (Han et al., 2025)	7B	61.3	-	-	39.0	74.3	46.2	-	-	-	41.4	64.2	24.3
X-Omni (Geng et al., 2025)	7B	62.8	62.6	-	47.2	-	-	76.8	81.5	70.4	-	-	-
Native UMMs													
BAGEL (Deng et al., 2025)	14B	66.4	72.8	67.2	55.3	85.0	71.9	89.2	78.5	73.3	70.2	82.5	41.7
Ming-UniVision (Huang et al., 2025a)	16B	59.4	59.1	64.2	40.3	71.0	56.8	82.8	76.7	72.4	48.2	76.8	26.7
Harmon (Wu et al., 2025d)	1.5B	58.9	49.8	-	38.9	61.7	41.6	57.0	29.8	11.2	41.9	67.0	25.1
JanusFlow (Ma et al., 2025b)	1.3B	60.3	41.2	36.2	29.3	67.7	39.8	54.2	42.4	53.2	42.9	78.6	22.0
Emu3 (Wang et al., 2024b)	8B	60.3	57.4	23.5	31.6	71.0	44.6	70.0	69.4	68.7	53.4	65.2	24.7
VILA-U (Wu et al., 2024)	7B	60.8	46.8	26.3	31.2	62.7	31.9	49.0	11.4	23.3	38.7	55.2	25.4
Janus-Pro (Chen et al., 2025c)	7B	62.0	58.0	41.1	41.0	73.3	56.3	71.3	25.8	59.0	47.6	53.2	23.8
Show-o2 (Xie et al., 2025b)	7B	63.1	64.7	39.6	48.9	76.7	61.3	78.6	52.3	32.4	44.5	63.5	26.9
OneCat (Li et al., 2025)	9B	63.1	65.2	52.2	41.9	71.3	61.6	77.8	81.2	79.0	63.4	34.2	24.9
TUNA (Liu et al., 2025)	7B	63.9	66.1	42.9	49.8	70.7	52.7	79.3	85.8	74.3	52.4	73.5	22.4
TUNA-R	7B	63.5	67.9	46.7	51.1	74.7	58.4	79.4	85.6	78.3	57.6	77.8	26.2
TUNA-2	7B	65.0	67.7	51.7	50.7	77.3	61.1	79.6	85.6	79.7	59.2	81.7	28.8

Results

图像生成（2个Benchmark， 13项指标）

Models	Size	GenEval							DPG-Bench					
		1-Obj.	2-Obj.	Count	Colors	Position	Col.	Attr.	Overall	Global	Entity	Attribute	Relation	Other
Generation-only Models														
SD3-M (Esser et al., 2024)	2B	0.99	0.94	0.72	0.89	0.33	0.60	0.74	87.90	91.01	89.96	80.70	88.68	84.08
FLUX.1 [dev] [†] (Batifol et al., 2025)	12B	0.98	0.93	0.75	0.93	0.68	0.65	0.82	82.10	89.50	88.70	91.10	89.40	84.00
LongCat-Image (Team et al., 2025)	6B	0.99	0.98	0.86	0.86	0.75	0.73	0.87	89.10	92.54	92.00	93.28	87.50	86.80
Qwen-Image (Wu et al., 2025a)	20B	0.99	0.92	0.89	0.88	0.76	0.77	0.87	91.32	91.56	92.02	94.31	92.73	88.32
Seedream 3.0 (Gao et al., 2025)	-	0.99	0.96	0.91	0.93	0.47	0.80	0.84	94.31	92.65	91.36	92.78	88.24	88.27
Z-Image-Turbo (Cai et al., 2025)	6B	1.00	0.95	0.77	0.89	0.65	0.68	0.82	91.29	89.59	90.14	92.16	88.68	84.86
Composite UMMs														
Tar (Han et al., 2025)	7B	0.99	0.92	0.83	0.85	0.80	0.65	0.84	83.98	88.62	88.05	93.98	84.86	84.19
BLIP3-o (Chen et al., 2025a)	8B	-	-	-	-	-	-	0.84	-	-	-	-	-	81.60
UniWorld-V1 [†] (Lin et al., 2025a)	12B	0.98	0.93	0.81	0.89	0.74	0.71	0.84	83.64	88.39	88.44	89.27	87.22	81.38
OmniGen2 [†] (Wu et al., 2025b)	7B	0.99	0.96	0.74	0.98	0.71	0.75	0.86	88.81	88.83	90.18	89.37	90.27	83.57
Native UMMs														
MUSE-VL (Xie et al., 2025c)	7B	-	-	-	-	-	-	0.57	-	-	-	-	-	-
Transfusion (Zhou et al., 2024)	7B	-	-	-	-	-	-	0.63	-	-	-	-	-	-
Emu3 (Wang et al., 2024b)	8B	-	-	-	-	-	-	0.66	-	-	-	-	-	81.60
Show-o2 (Xie et al., 2025b)	7B	1.00	0.87	0.58	0.92	0.52	0.62	0.76	89.00	91.78	89.96	91.81	91.64	86.14
Janus-Pro (Chen et al., 2025c)	7B	<u>0.99</u>	0.89	0.59	0.90	0.79	0.66	0.80	86.90	88.90	89.40	89.32	89.48	84.19
HBridge [†] (Wang et al., 2025d)	7B	1.00	<u>0.96</u>	0.80	<u>0.94</u>	0.77	0.78	0.87	91.78	91.82	90.23	90.06	88.42	85.23
Ming-UniVision (Huang et al., 2025a)	16B	1.00	0.93	0.59	0.93	0.92	0.70	0.85	-	-	-	-	-	82.12
BAGEL [†] (Deng et al., 2025)	14B	0.98	0.95	0.84	0.95	0.78	0.77	0.88	88.94	90.37	<u>91.29</u>	90.82	88.67	85.07
Mogao (Liao et al., 2025)	7B	1.00	0.97	<u>0.83</u>	0.93	0.84	<u>0.80</u>	<u>0.89</u>	82.37	90.03	88.26	<u>93.18</u>	85.40	84.33
TUNA (Liu et al., 2025)	7B	1.00	0.97	0.81	0.91	<u>0.88</u>	0.83	0.90	<u>90.42</u>	91.68	90.94	91.87	<u>90.73</u>	86.76
TUNA-R	7B	1.00	0.95	0.82	0.89	0.86	0.79	0.88	86.00	<u>91.80</u>	91.03	93.48	84.89	86.35
TUNA-2	7B	<u>0.99</u>	<u>0.96</u>	0.80	0.91	0.84	0.76	0.87	89.50	91.40	92.07	91.91	88.81	<u>86.54</u>

基于GPT-5.4和Claude Opus 4.7的评估结果

Models	GPT-5.4		Claude Opus 4.7	
	Quality	Diversity	Quality	Diversity
TUNA	22.3%	20.6%	28.1%	28.2%
TUNA-R	35.7%	<u>30.9%</u>	37.2%	<u>29.9%</u>
TUNA-2	<u>32.1%</u>	48.4%	<u>34.8%</u>	41.9%

Results

图像编辑 (ImgEdit)

Models	Add	Adj.	Ext.	Rep.	Rm.	Bg.	Sty.	Hyb.	Act.	Total
Generation-only Models										
FLUX.1	4.25	4.15	2.35	4.56	3.57	4.26	4.57	3.68	4.63	4.00
Qwen-Image	4.38	4.16	3.43	4.66	4.14	4.38	4.81	3.82	4.69	4.27
Unifed Models										
OmniGen	3.47	3.04	1.71	2.94	2.43	3.21	4.19	2.24	3.38	2.96
BAGEL	3.56	3.31	1.70	3.30	2.62	3.24	4.49	2.38	4.17	3.20
UniWorld	3.82	3.64	2.27	3.47	3.24	2.99	4.21	2.96	2.74	3.26
OmniGen2	3.57	3.06	1.77	3.74	3.20	3.57	<u>4.81</u>	2.52	4.68	3.44
GPT-Image	4.61	<u>4.33</u>	2.90	<u>4.35</u>	<u>3.66</u>	4.57	4.93	<u>3.96</u>	4.89	<u>4.20</u>
TUNA	<u>4.43</u>	4.48	<u>2.46</u>	4.65	4.55	<u>4.52</u>	4.69	4.22	<u>4.76</u>	4.31
TUNA-R	4.46	4.27	2.38	4.61	4.48	4.44	4.54	4.06	4.43	4.18
TUNA-2	4.34	4.13	2.22	4.53	4.42	4.36	4.58	3.91	4.28	4.09

在极度讲究保真度的细粒度编辑场景里，保留编码器的先验可能还是有用的。


生成能力Tuna-R、Tuna-2整体比Tuna稍弱

Ablation


Masking Ablation

	General Understanding		Pixel-Centric	Genaration
Models	OCRBench	MMVP	CountBench	GenEval
TUNA	56.9	54.0	55.6	57.2
TUNA-R w/o Masking	58.3	56.7	57.2	55.7
TUNA-R w/ Masking	59.2	58.0	58.2	56.0
TUNA-2 w/o Masking	55.4	52.3	53.4	47.6
TUNA-2 w/ Masking	56.8	55.7	57.6	48.2

起步慢，后劲足



Analysis&Visualization



1.去掉 VAE 不一定是好事

图像生成、编辑任务性能倒退

2.训练成本会很高

无 encoder 路线可能需要更充分、更昂贵的预训练才能赢。

3.消融不够充分

优势到底来自 encoder-free 架构、像素空间 flow matching、masking 策略、数据规模？

Conclusion

当模型、数据和训练规模足够大时，直接从像素学习统一的理解与生成表示，可能比依赖外部视觉编码器更有上限。

- 挑战视觉 encoder 的必要性

说明统一多模态模型不一定必须依赖预训练视觉 encoder。

- 推进更彻底的端到端统一建模

理解和生成尽量共享同一套像素级视觉表示。

- 证明 pixel embeddings 有 scaling 潜力

在充分训练后，简单 pixel patch embeddings 可能超过外部视觉 encoder。

- 重新审视 VAE latent 的作用

VAE 很高效，但也可能带来压缩瓶颈和细节损失。

Vision Encoder是训练捷径，但Pixel Embedding上限可能更高