





一. 图像多模态大模型 (CLIP&SigLIP&LLaVA)

1. CLIP: 跨模态对比学习




额外添加的<cls> token, 聚合图像的全局语义特征
最终输出用于图像分类


(1) Contrastive pre-training



(2) Create dataset classifier from label text



(3) Use for zero-shot prediction



通过对比学习将图像和文本映射到同一向量空间，实现了强大的零样本（Zero Shot）图像分类能力。

2. SigLIP: Sigmoid Loss for Language Image Pre-Training

CLIP Softmax Loss: 在一堆选项选出“最匹配”的那个

$$\mathcal{L}_{\text{img}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\mathbf{S}_{i,i}/\tau)}{\sum_{j=1}^N \exp(\mathbf{S}_{i,j}/\tau)}$$


$$\mathcal{L}_{\text{text}} = -\frac{1}{N} \sum_{j=1}^N \log \frac{\exp(\mathbf{S}_{j,j}/\tau)}{\sum_{i=1}^N \exp(\mathbf{S}_{i,j}/\tau)}$$

$$\mathcal{L}_{\text{CLIP}} = \frac{\mathcal{L}_{\text{img}} + \mathcal{L}_{\text{text}}}{2}$$

	T ₁	T ₂	T ₃	...	T _N
I ₁	I ₁ ·T ₁	I ₁ ·T ₂	I ₁ ·T ₃	...	I ₁ ·T _N
I ₂	I ₂ ·T ₁	I ₂ ·T ₂	I ₂ ·T ₃	...	I ₂ ·T _N
I ₃	I ₃ ·T ₁	I ₃ ·T ₂	I ₃ ·T ₃	...	I ₃ ·T _N
⋮	⋮	⋮	⋮	⋱	⋮
I _N	I _N ·T ₁	I _N ·T ₂	I _N ·T ₃	...	I _N ·T _N

SigLIP Sigmoid Loss: 判断一对图像和文本是否匹配

$$-\frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \sum_{j=1}^{|\mathcal{B}|} \underbrace{\log \frac{1}{1 + e^{z_{ij}(-t\mathbf{x}_i \cdot \mathbf{y}_j + b)}}}_{\mathcal{L}_{ij}}$$



小批次表现更佳
饱和速度快

SigCLIP: 32k

CLIP: 98k

更省内存

4 块 TPU-v4

SigLIP 可以放下 4096
batch size, CLIP 只能
放下 2048

Batch内所有图文对做全局 softmax归一化，正样本对概率最大化

特性	CLIP (基于Softmax)	SigLIP (基于Sigmoid)
问题定义	多分类问题：从一批文本中找出与给定图像最匹配的那一个。	二元分类问题：判断任意一个图像-文本对是否匹配。
样本依赖	强耦合：计算一个样本的损失，需要用到批次内所有其他样本（作为负样本）。	完全独立：每个图像-文本对的损失可以独立计算，互不影响。（便于分布式扩展）
批次大小	极度依赖大批次：需要成千上万的负样本来保证效果。	对批次大小不敏感：即使在小批次下也能稳定训练，性能更优。
计算效率	较低，需要构建和归一化整个 $N \times N$ 的相似度矩阵。	更高，无需全局归一化，内存和通信开销都更小。


SigLIP在无需大规模计算资源的情况下，在性能上能达到甚至超越依赖海量算力的 CLIP

做复杂、类数很多的分类任务，可以由softmax分类转向二元分类
即：某个样本属于哪个类别——>是否是某个类别

2. LLaVA 系列

用最简单的架构（ ViT + Linear Layer + LLM ）证明了：只要数据质量够高，复杂的连接层是不必要的。

LLAVA1



两阶段训练：

阶段一：特征对齐预训练

使用约 60 万对的“图像-指令-回答”数据（LLaVA-Instruct-558k）

- ✗ 冻结 Vision Encoder (CLIP ViT)。
- ✗ 冻结 LLM (Vicuna/Llama)。
- ✓ 仅训练 Projector (Linear Layer)。

阶段二：多模态指令微调

使用高质量的 LLaVA-Instruct-158K 数据集

- ✗ 冻结 Vision Encoder
- ✓ 训练 Projector + 训练 LLM (通常全量微调或 LoRA)。

利用 GPT-4 生成的合成数据

- 对话：58K 条，侧重日常交流。
- 详细描述：23K 条，侧重对画面的全面刻画。
- 复杂推理：77K 条，需要模型理解场景语义、做常识推断，甚至预测后果。

LLaVA系列模型比较

核心维度	LLaVA-1.0	LLaVA-1.5	LLaVA-NeXT (1.6)
视觉分辨率	224 × 224	336 × 336	672 × 672（及任意分辨率）
跨模态连接器	单层线性层（Linear）	两层 MLP	沿用两层 MLP
语言模型底座	Vicuna-13B	Vicuna-13B / 7B	Yi-34B / LLaMA-3 / Qwen
核心能力突破	基础的图文对话与描述	细节识别更强，幻觉大幅减少	顶尖的OCR、复杂推理与世界知识