# 针对特定垂直领域的无参考视频质量评估

# （NR-VQA）

# No-Reference Vedio Quality Assessment

**UGC视频（YouTube、TikTok等）质量参差不齐**

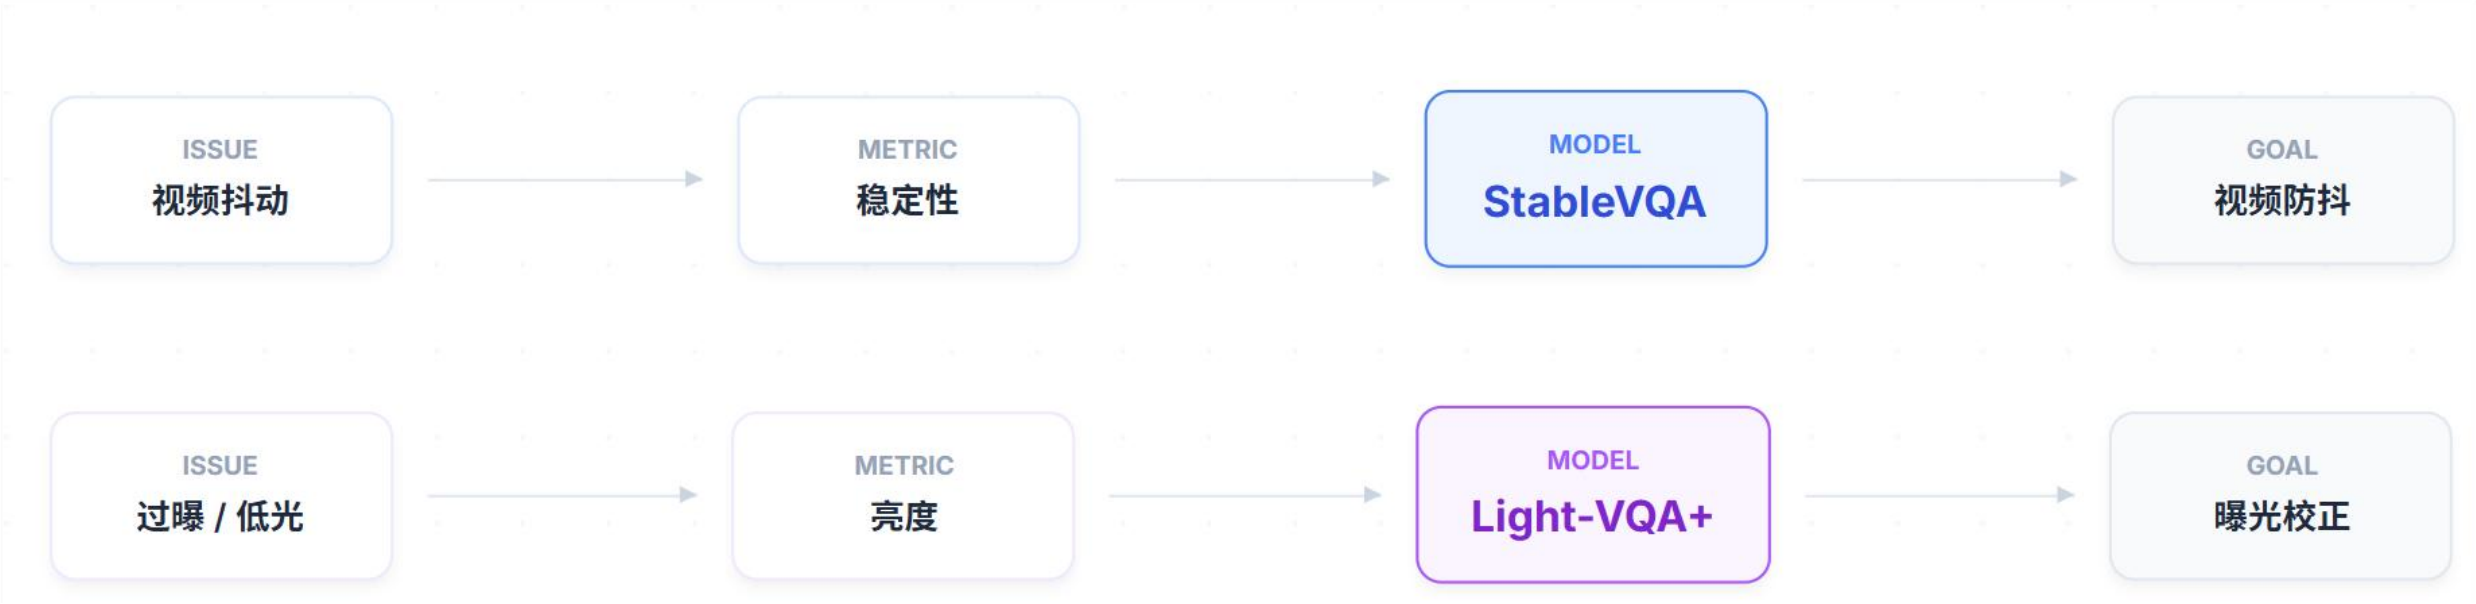


**说明:Light-VQA+是Light-VQA(仅针对低光)的扩展版。专注于曝光校正(VEC)，包含低光增强和过曝恢复。**

# Assessment Taxonomy

## 主观 VQA

SUBJECTIVE ASSESSMENT

由人类观察者（专家或普通用户）在受控环境下对视频进行观看并打分。

- **指标:** 平均意见得分 (MOS, Mean Opinion Score)。
- **地位:** 质量评估的“黄金标准”，所有客观算法的对齐目标。

**⚠ 局限性**

极度耗时、昂贵，且无法用于实时监控或大规模系统。

## 1. 全参考 (FR)

FULL-REFERENCE

**定义与原理**

评估时需要**完整的、无失真的原始视频**作为参考。通过逐帧、逐像素对比失真视频与参考源的差异（如信号保真度）。

**典型指标**

PSNR, SSIM, VMAF。

**痛点:** 在 UGC 场景（如抖音/YouTube）中，用户上传的即为“源”，不存在更高质量的参考标准，因此**完全不可用**。

## 2. 简化参考 (RR)

REDUCED-REFERENCE

**定义与原理**

不需要完整视频，仅需从源视频提取的**部分特征信息**（如边缘统计量、直方图、特定水印等）通过辅助通道传输。

**定位**

FR 与 NR 之间的折中方案。

**优势:** 大幅降低了带宽需求，比 NR 更可靠，但仍需源端配合提取特征。

## 3. 无参考 (NR)

NO-REFERENCE / BLIND VQA

**定义与原理**

**完全不需要**任何参考视频。算法直接分析待测视频的**内在统计特征**（如自然场景统计 NSS）或利用深度学习模型提取语义与失真特征，直接回归预测质量分数。

**适用场景**

真实世界的 UGC 视频评估（包含复杂的混合失真：**抖动、过曝、压缩伪影**）。

**结论:** 本研究的核心领域，最实用但挑战性最大。

# Background&Challenge

## UGC 视频稳定性

**拍摄现状**

非专业手持、运动场景拍摄导致画面剧烈晃动。

**现有技术**

虽有防抖算法，但缺乏评估其效果的客观标准。

**评估指标**

最常用指标 Stability Score失效严重：
原理：低频能量越高越稳定。
缺陷：前景运动物体干扰（误判为抖动）；
严重抖动导致运动模糊，匹配失败。

**共同原因：**

**通用VQA模型综合评估质量不专精于稳定性、曝光等，需要专用模型**

## 视频曝光校正 (VEC)

**拍摄现状**

非专业手持、自动曝光失效导致画面过曝/欠曝。

**现有技术**

虽有众多增强算法（低光增强（LLVE）和过曝恢复（OEVR）），但缺乏客观评估其效果的客观标准。
图像级处理（LLIE/OEIR）：逐帧处理，易导致时序闪烁
视频级算法（如StableLLVE）：考虑一致性，但仍需准确质量评估

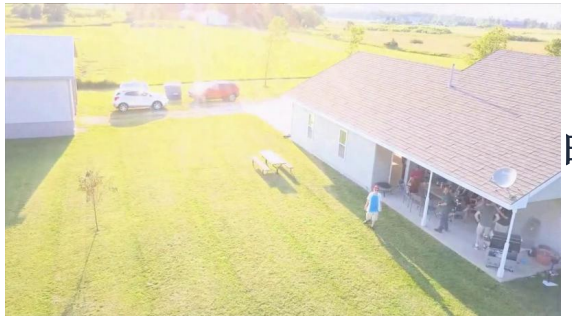

**曝光过度(Over-Exposure)**

**曝光不足(Under-Exposure)**

# Database

## StableDB

视频稳定性 (VQA-S)

首个针对**画面抖动**评估的大规模主观数据集，专注于解决 UGC 视频的稳定性问题。

## VEC-QA

曝光校正 (VEC)

涵盖**低光照增强**与**过曝恢复**的综合数据集，包含原始视频及其对应的增强/恢复版本。

| 维度 | STABLEDB 详情 | VEC-QA 详情 |
| --- | --- | --- |
| 数据总量 | **1,952** 个视频 | **4,518** 个视频<br>含 254低光+1806增强; 205过曝+2253恢复 |
| 主观评分 (MOS) | **34 位受试者**<br>评分维度：稳定性程度 (Stability) | **21 位专家/评估员**<br>评分维度：整体感知质量 (亮度/噪点/稳定性) |
| 视频规格 | 720p 8秒 MP4 | 720p 8-10秒 |
| 数据来源 | KoNViD-1k V3C1 LIVE-Qualcomm NUS DeepStab Selfie 自摄 (70个) | LLVE-QA KoNViD-1k VDPVE YouTube-UGC LIVE-VQC Vimeo |

# StableVQA

通过三支路分别提取光流特征（3D ResNet捕捉相机运动）、语义特征（Swin Transformer排除前景干扰）和模糊特征（Blur Encoder处理运动模糊），经平均池化拼接融合后由MLP回归预测稳定度分数，实现与人眼主观感知高度一致的精准评估。

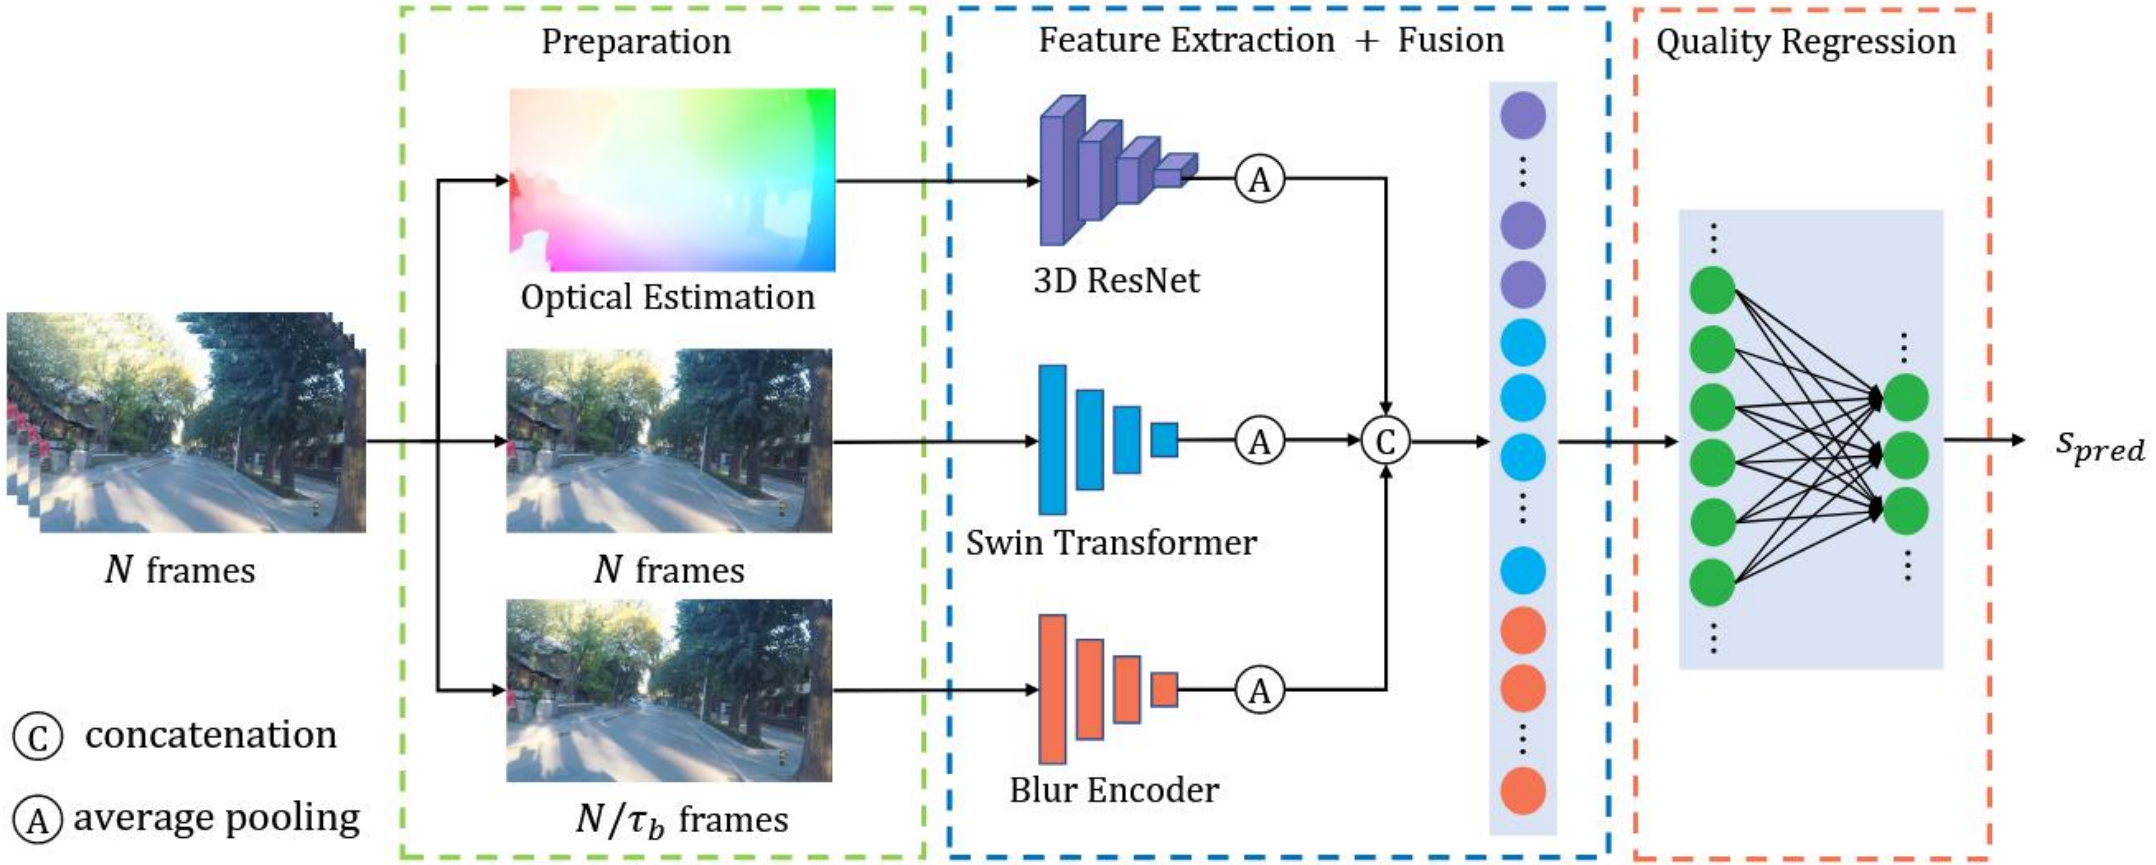

# Light-VQA+

通过 CLIP 结合精心设计的视觉-语言提示提取亮度、噪声与时序一致性特征，经 cross-attention 时空融合并引入可训练 **HVS 注意力权重**加权 clip 分数，实现与人眼感知高度一致的精准评估。

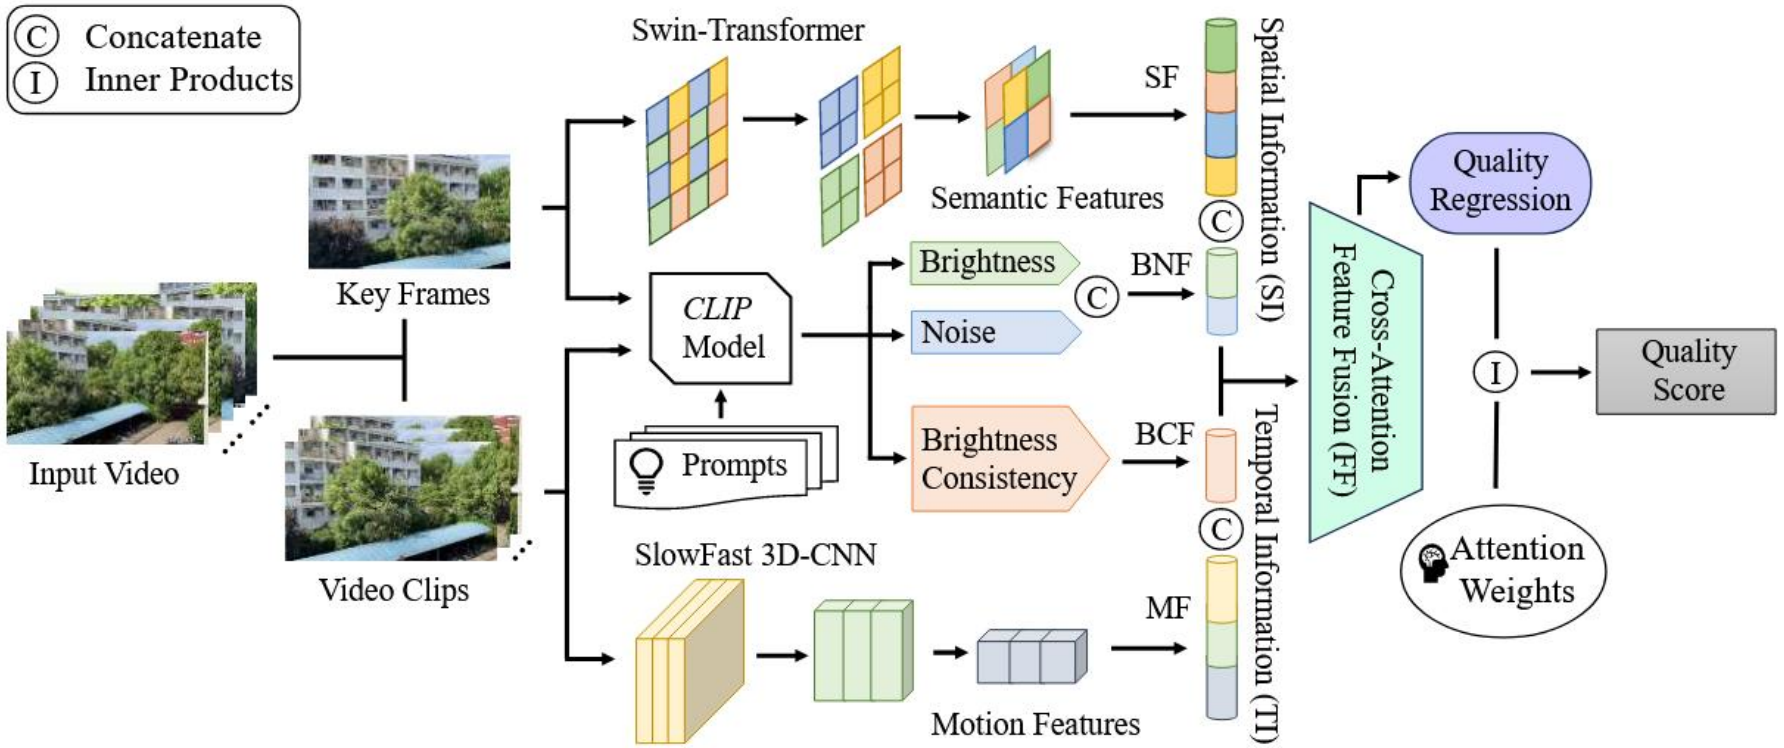


## Prompts

- 亮度
  a bright photo（明亮的照片）
  a dark photo（黑暗的照片）
- 噪声
  a noisy image（噪声大的图）
  a clean image（干净的图）
- 一致性
  consistent brightness between frames（帧间亮度一致）
  inconsistent brightness（不一致）

# Conclusion

- **“特化” vs “通用”：**

两篇文章都证明了：在曝光和防抖这种强垂直领域，引入**领域先验知识（Domain Knowledge）** 比纯粹的大模型通用特征更有效。

Light-VQA+ 的先验是“Prompt 设计”（模型关注亮度/噪声/时序一致性）。

StableVQA 的先验是“物理特征设计”（光流代表运动，模糊代表快门拖影）。

- **多模态大模型 (MLLM) 的应用：**

Light-VQA+ 积极拥抱 MLLM（CLIP），利用其 Zero-shot 能力提取特定属性 。

StableVQA 相对传统，采用的是“专家模型集成”思路（光流网络 + 去模糊网络 + Transformer）。

- **局限性 ：**

StableVQA特征融合简单（concat）

### 4.3 Feature Fusion

After feature extraction, we propose a feature fusion module to obtain an overall feature of the video. Firstly, adaptive average pooling is deployed for all three branches to unify features in the channel dimension. Then the overall feature is obtained by a concatenation:

$$f = cat(avg_pool(f_o, f_s, f_b)), \tag{4}$$

where $f \in \mathbb{R}^{(C_o+N\times C_s+N_b\times C_b)\times 1}$. It is worth noting that a variety of fusion strategies can be leveraged for feature fusion, *e.g.*, attention-based. However, they are beyond the scope of this paper.